

무장애·가족 친화 관광 챗봇 시제품 검토 자료

마지막 갱신: 2026-05-15

1. 검토 목적

검토받고 싶은 핵심

- 범위:** 2026-06-10까지의 시제품 범위가 현실적인가
- 구조:** RAG, TourAPI, LLM 사용 구조가 타당한가
- 일정:** 데이터 수집·평가·시연 준비에서 줄일 것과 남길 것이 무엇인가
- 발표:** 강조할 차별점이 무엇인가

2. 요약

핵심 문장: 일반 RAG 문서 검색 챗봇을 기반으로, 한국관광공사 OpenAPI와 로컬 벡터 검색 자료를 결합해 무장애·가족 친화 관광지를 근거 기반 카드로 추천하는 상담형 시제품을 만든다.

현재 검증 초점

- 접근성 조건:** 휠체어, 유아차, 고령자, 어린 자녀 동반
- 지역명 모호성:** 중구, 남구처럼 여러 지역에 있는 지명
- 환각 억제:** 근거 부족 시 확인 필요 또는 결과 부족 표시
- 시연 화면:** 카드, 출처, 주의 문구를 웹에서 확인

3. 기술 구조

요소	프로젝트 내 역할
RAG	관광 Markdown/문서를 먼저 검색해 답변 근거로 사용
LLM	후보 장소를 만들지 않고, 후보 카드의 순서·상담 문장·확인 메모만 보조
임베딩/ChromaDB	질문·문서를 벡터화하고 로컬 벡터DB에서 유사도 검색
TourAPI	한국관광공사 OpenAPI. 캐시/RAG에 없을 때만 실시간 조회
캐시/폴백	반복 API 호출을 줄이고, 실패 시 미리 수집한 자료로 응답 유지
eval/이벤트 로그	20문항 평가와 질문-카드 연결 기록으로 품질 분석

응답 흐름:

질문 -> 지역/조건/확장 의도 구조화 -> 모호 지역이면 선택 후보 반환
-> 카드 캐시 확인 -> RAG/ChromaDB 검색 -> 없으면 TourAPI 조회
-> 관광지 카드 생성 -> 필요 시 LLM 보조 -> 답변/카드/출처/주의 문구 반환

기본 전략: 캐시/RAG 우선 + 부족할 때 TourAPI live-on-miss.

매번 API를 호출하지 않고, 저장 자료와 검색 자료를 먼저 사용한다.

4. 범위

포함

- 질문 처리: 자연어 관광 질문, 지역/조건/확장 의도
- 데이터 경로: TourAPI 조회, RAG 검색, 폴백 자료
- 시연 화면: 웹 확인 화면, 지역 선택 버튼, 추천 카드
- 품질 검증: pytest, 20문항 eval, 이벤트 로그

제외/후순위

- 일정 자동 생성, 예약/결제, 모바일 앱 완성
- 전국 모든 관광지 전체 수집
- 정식 운영 대시보드
- 일반 관광 전체 확장, 병원/약국/응급의료기관 결합

5. 주요 설계 결정

결정	이유와 보완
캐시/RAG 우선	호출량 절감과 시연 안정성. 데이터 신선도는 주기적 갱신으로 보완
좁은 지역 자동 확장 금지	사용자가 요청한 지역을 임의로 넓히지 않음. 부족하면 부족 안내
동명이 지역 추가 질문	중구, 남구 등 지역 오인 방지. UI에서 빠른 선택 버튼 제공
가족 호칭만으로 고령자 추정 금지	휠체어 사용자를 고령자로 단정하지 않음. 명시 조건만 처리
LLM은 상담 보조로 제한	환각 방지. 후보 카드 밖의 장소·접근성 정보 생성 금지
의료 안전 정보는 후속 확장	가치가 크지만 최신성·책임 범위 부담. 위치/운영 정보 안내로 제한

6. 현재 구현·데이터 상태

영역	상태
서버/API	/tourism/chat 구현, 안전한 오류 응답, 진단 정보, 이벤트 로그
데이터/RAG	TourAPI 후보 조회, 무장해 상세 조회, ChromaDB 검색, Markdown 폴백
지역 처리	동명이 지역 추가 질문, 행정동/법정동 매칭 데이터
웹 확인	자유 질문, 지역 선택 버튼, 카드 표시, Help 팝업, Swagger/ReDoc 링크
테스트/eval	자동 테스트 71개 통과, 20문항 fallback-only 1차 실행, API 실패 0건
모델 비교	SuperGemma, Gemma4, Qwen3 후보 1차 비교

데이터 수치

- 미리 수집한 관광 자료: 460개
- ChromaDB 색인: 461개 문서 / 463개 조각
- 중복 콘텐츠ID: 16개 분석 후 0개로 정리
- TourAPI 지역 코드: 234개 기준
- 3장 이상 확보 시군구: 90개
- 시군구 3장 목표 남은 부족분: 약 365장

진행도 요약: 시제품 전체 77%, 서버 응답 계약 90%, 웹 시연 화면 70%, 품질 평가 70%, 운영 준비 20%.

7. 품질 개선 작업

작업	목적
샘플 감사·중복 정리	필드 누락, 파싱 실패, 중복 콘텐츠ID 점검
행정동/법정동 매칭	좌동, 마산합포구, 분당구 같은 실제 표현 처리
동명이 지역 clarification	중구, 남구 등 지역 오인 방지
안전한 오류·폴백 진단	내부 예외 노출 방지, OpenAPI/RAG 실패 상태 표시
이벤트 로그	질문과 추천 카드 매칭 분석 기반 마련
모델 벤치마크	LLM 보조의 품질·지연 시간 확인
웹 테스트 화면	비개발자도 카드/출처/주의 문구 확인 가능

8. LLM 모델 판단

모델	1차 판단
현재 SuperGemma 기본 모델	한국어 상담 기본 후보. 별도 사고 과정은 미지원
gemma4:e4b	native thinking 가능하나 30초 이상 지연
huihui_ai/gemma-4-abliterated:e4b	native thinking 가능하나 지연과 안전 필터 약화 검토 필요
qwen3:4b	thinking은 가능하나 현재 JSON/한국어 계약 준수 부족

현재 방침: 짧은 LLM 보조 방식 유지, 후보 카드 밖 정보 생성 금지, 모델 내부 사고 과정 비노출.

9. 남은 작업

공개 데모 전 필수

- 20문항 eval 수동 채점 및 live-on-miss 재실행
- 부족 지역 보강, 모바일/외부 접속 점검
- 대표 화면 캡처, 시연 모드 결정

품질 보강

- 전국 실사용 지역 250개 기준 재정리
- 시군구 폴백 부족분 보강
- TourAPI 영속 캐시 설계
- 이벤트 로그 SQLite 전환 검토

후순위

- 모바일 앱 전환, 주기적 데이터 갱신, 정식 배포
- 관리자 대시보드, 병원/약국/응급의료기관 결합 검토

10. 주요 리스크

리스크	대응과 남은 과제
OpenAPI 호출량 제한	캐시/RAG 우선, 폴백 전용 시연 옵션. 영속 캐시와 일일 호출량 관리 필요
지역 데이터 부족	460개 폴백 자료와 1차 시군구 수집 완료. 부족 지역 보강 필요
지역명 오인	동명이 지역 추가 질문과 행정동/법정동 매칭. 전국 250개 기준 검증 필요
접근성 정보 환각	카드 스키마와 확인 필요 정책. eval 수동 채점과 프롬프트 보강 필요
응답 지연·데이터 신선도	LLM 보조 제한과 저장 자료 중심 운영. 제한 시간 기준과 주기적 갱신 필요
의료 정보 확장	후속 범위로 분리. 의료 판단 금지와 위치/운영 정보 제한 필요

11. 교수님께 확인받고 싶은 질문

- 1. **범위**: 시제품 범위가 2026-06-10까지 현실적인가?
- 2. **구조**: 캐시/RAG 우선 + TourAPI live-on-miss 전략이 공모전 목적에 맞는가?
- 3. **지역 정책**: 동명이 지역 추가 질문과 좁은 지역 자동 확장 금지 정책이 사용자 관점에서 타당한가?
- 4. **LLM 경계**: LLM을 후보 생성자가 아니라 상담 보조로 제한하는 방향이 적절한가?
- 5. **발표 차별점**: 환각 억제, 출처 기반 카드, RAG/폴백 안정성, 지역명 현실성, eval 기반 검증 중 무엇을 전면에 둘까?
- 6. **후속 확장**: 일반 관광과 병원/약국 안전 정보 확장을 후속 연구·개발 방향으로 두는 판단이 적절한가?

12. 참고 문서

docs/project/G0AL.md, docs/project/progress_overview.md,
docs/project/mvp_quality_work_log.md, docs/tourism/accessible_tourism_mvp_plan.md,
docs/tourism/tourism_response_strategy_decision.md,
docs/tourism/tourism_eval_questions.md,
docs/tourism/tourism_model_reasoning_benchmark.md, README.md