

무장애·가족 친화 관광 챗봇 시제품 검토 자료

마지막 갱신: 2026-05-17

1. 검토 목적

검토받고 싶은 핵심

- 시연 적합성: 현재 완성도가 공모전 시연용 MVP로 충분한가
- 제품 범위: 무장애 관광 추천에 집중하고, 의료·예약·실시간 정보는 제외하는 판단이 맞는가
- 기술 구조: TourAPI, 로컬 fallback, RAG, 규칙 기반 처리와 ML 보조 신호의 조합이 타당한가
- 품질 근거: 자동 eval, 실제 브라우저 QA, blind eval 결과를 발표에서 어떻게 설명할까
- 표현 방식: 접근성 정보를 “보장”이 아니라 “공식 데이터 기반 추천”으로 안내하는 방식이 충분히 안전한가

2. 한 줄 요약

한국관광공사 무장애 여행 정보와 로컬 RAG/fallback 자료를 결합해, 지역·접근성 조건을 이해하고 근거가 있는 관광지 카드를 추천하는 상담형 시제품이다.

현재 문서는 공모전 시연 범위와 후속 검수 범위를 교수님께 확인받기 위한 검토 자료다. 단순히 LLM을 붙인 챗봇이 아니라, 자연어 의도와 대화 문맥을 따로 분석하고 그 결과를 추천 품질 평가에 연결했다는 점을 설명한다.

3. 현재 완성도

영역	상태	근거
/tourism/chat API	구현 완료	지역/조건/후속 질문/더 보기/최신 정보 더 찾기/부족 안내 처리
웹 UI	구현 완료	개발 모드와 릴리즈 모드 분리, 모바일 1열 카드, 상세 정보, 지도 검색
데이터	최소 안전망 확보	904개 fallback Markdown, Chroma 905개 문서 / 914개 청크
지역 커버리지	대부분 확보	TourAPI 234개 중 228개 시군구가 공식 무장애 상세 3장 이상
평가	주요 회귀 통과	551건 자동 eval fallback-only/live-enabled 모두 실패 0건
실제 UI QA	통과	Playwright 개발 20/20, 릴리즈 20/20, 전체 40/40
운영 준비	낮음	정식 배포, 모니터링, 사람 검수, 영속 캐시는 후속

4. 기술 구조

요소	역할
FastAPI	/tourism/chat, /tourism-ui/, 상태 확인 API 제공
TourAPI	한국관광공사 무장애 여행 정보 후보와 상세 접근성 정보 조회
로컬 fallback	API 실패·쿼터-네트워크 불안 시에도 응답 가능한 Markdown 카드
ChromaDB/RAG	저장된 관광 카드와 문서를 검색해 후보 근거 확보
규칙 파서	지역, 조건, 제외, 더 보기, 최신 조회, 미지원 요청 처리의 1차 기준
ML 보조 분류기	의도/문맥 판단 보조. 규칙을 대체하지 않고 헛갈리는 표현을 확인
LLM 추론 보조	기본 OFF. 커도 후보 생성이 아니라 카드 재랭킹/확인 메모 보조로 제한

응답 흐름:

질문

- > 지역/조건/후속 의도 해석
- > 모호 지역이면 선택 질문
- > cache / RAG / fallback 후보 확인
- > 부족하거나 사용자가 요청하면 live TourAPI 보강
- > 조건 근거가 있는 카드만 추천
- > 출처, 주의 문구, 후속 제안 반환

5. 사용자 경험

시연 화면은 /tourism-ui/ 다.

- 기본 개발 모드: API 주소, Swagger/ReDoc/OpenAPI, DBG 진단 패널 노출
- 릴리즈 모드: ?mode=release 또는 ?debug=0, 내부 진단 숨김
- 사용자 질문 말풍선, bot typing indicator, toast, 카드 등장 애니메이션
- 추천 카드 상세 정보 펼침
- 장소명/주소 기반 지도 검색
- 추천 카드 위 긴 답변 기본 접힘, 전체 보기/접기
- 브라우저 세션별 session_id 유지, 비우기로 새 세션 시작

6. 데이터와 지역 기준

항목	현재 기준
fallback Markdown	904개
Chroma 색인	905개 문서 / 914개 청크
TourAPI 광역	17개
TourAPI 시군구	234개
행안부 현행 시군구 alias 매칭	228개
3장 이상 공식 무장에 상세 확보	228개 시군구
공식 무장에 상세 3장 미만	계룡시 1장

주의할 점:

- 청원군, 마산시, 진해시, 남제주군, 북제주군은 부족 지역으로 표시하지 않는다.
- 위 이름들은 현재 행정구역 기준 안내 예외로만 관리한다.
- 사용자 화면에는 “현재는 청주시/창원시/서귀포시/제주시 기준으로 안내드릴게요”처럼 짧게 안내한다.
- 계룡시는 2026-05-17 재수집에서도 무장에 전용 목록이 1건만 반환됐다. 일반 관광 검색 8건 중 나머지 7건은 무장에 상세가 비어 있어 접근성 카드로 편입하지 않았다.

7. 자연어 처리와 ML 활용

질문을 그대로 LLM에 넘기지 않고, 먼저 아래 정보를 분리해 처리한다.

- 사용자가 원하는 행동: 추천, 더 보기, 조건 변경, 제외, 최신 조회 등
- 이어받을 대화 조건: 지역, 접근성 조건, 가족/이동 편의, 제외 선호
- 추천 제어 방식: 규칙 기반 처리를 중심으로 두고, ML은 보조 신호로 사용
- 평가 방식: 라벨 점수와 실제 chat 카드 품질을 분리해 확인

7.1 의도 분류

- 목적: 사용자의 다음 행동을 분류한다.
- 대상: 추천, 더 보기, 최신 정보, 조건 추가, 조건 교체, 조건 제외, 지역 변경, 미지원 요청.
- 데이터: 자체 발화, AI Hub 관광 대화 추출 발화, 경계 사례, 실제 chat 평가셋.
- 현재 적용: 규칙 기반 처리가 주도하고, 문자 n-gram Naive Bayes는 보조 신호로 사용한다.
- 예시: 오늘 환율 알려줘는 비관광 요청으로 차단한다.
- 예시: 응급실은 말고 관광지만 계속은 부정 표현을 보고 관광 문맥을 유지한다.

항목	지표	결과
의도 분류 학습셋	학습 row 수	16,254 rows
내부 holdout	accuracy	0.9164
AI Hub/adversarial holdout	accuracy	0.9229
Gemini verified holdout	accuracy	0.8536
hard intent holdout	accuracy	0.9747
region clarify natural holdout	accuracy	0.9800
change/replace 실제 chat holdout	자동 채점 통과율	201/201
adversarial chat holdout	자동 채점 통과율	42/42

7.2 문맥 해석

- 목적: 추천 결과를 바꾸는 조건 해석을 분리한다.
- strict 조건: 둘 다, 반드시처럼 모든 조건이 필요한 요청.
- soft 조건: 가능하면, 있으면 좋고처럼 완화 가능한 요청.
- OR 조건: 수어 또는 자막처럼 둘 중 하나면 되는 요청.
- 조건 교체: 유모차 말고 휠체어처럼 기존 조건을 바꾸는 요청.
- 조건 제외: 시장 말고, 카페 제외처럼 빼야 하는 선호.
- 시설 근거: 휠체어, 유모차, 수유실, 점자블록, 가족 편의처럼 카드 근거가 필요한 요청.

접근	역할
rule-only	명시 표현을 직접 처리하는 기준선
Naive Bayes	가벼운 문자 n-gram baseline
LinearSVC	sparse text feature 기반 선형 분류
LogisticRegression	확률 기반 선형 분류
hybrid LinearSVC / LogisticRegression	규칙 결과와 선형 모델 결합
KLUE-RoBERTa small	transformer fine-tuning 후보
SuperGemma4 selective labeling	오답 재라벨링과 검수 보조 실험

평가	결과
context locked test 최신	micro-F1 0.9803
independent validation 최신	micro-F1 0.9741
specific-facility adversarial	micro-F1 0.9946
rotating blind v4 rule-only	micro-F1 0.9091
rotating blind v4 hybrid LinearSVC	micro-F1 0.9012
rotating blind v4 hybrid LogisticRegression	micro-F1 0.8968
실제 chat blind v2	15/15 통과

지표 해석:

- v1/v2/v3: 발견한 오류를 고친 뒤의 회귀 점검 결과.
- v4 blind: 새 평가셋 기준으로 일반화 가능성을 확인한 결과.
- v4에서는 rule-only가 hybrid LinearSVC/LogisticRegression보다 조금 높았다.
- 현재 런타임은 복합 ML 모델로 교체하지 않는다.
- 규칙 기반 처리를 중심에 두고, ML은 보조 신호로 유지한다.
- 실제 chat blind v2 15/15 결과를 함께 보고 카드 품질을 확인한다.

7.3 Transformer와 LLM 채택 판단

- KLUE-RoBERTa small fine-tuning도 비교했다.
- validation micro-F1은 0.9241이었다.
- locked test 단독 micro-F1은 0.8594였다.
- rule hybrid micro-F1은 0.9474였다.
- 기존 기준선을 넘지 못했고, 응답 지연도 더 길었다.

- 따라서 런타임 교체는 보류했다.
- SuperGemma4 selective labeling은 일부 exact를 올렸지만 micro-F1이 하락했다.
- SuperGemma4는 런타임 판단자가 아니라 QA/재라벨링 보조로 둔다.
- 결론: 현재 구조는 규칙 기반 처리 + ML 보조 신호 + 실제 chat 평가 조합이다.
- LLM은 후보 생성 엔진이 아니라, 필요할 때 카드 순서와 설명을 보조하는 역할로 제한한다.

7.4 현재 런타임에서 쓰는 방식

현재 챗봇은 룰셋만으로 동작하지 않는다. 다만 최종 행동 결정의 중심은 규칙 기반 처리이고, ML과 RAG는 아래 위치에서 보조한다.

구성	실제 역할
규칙 파서	지역, 조건, 제외, 교체, 더 보기, 최신 조회, 미지원 요청을 1차 판단
의도 분류기	문자 n-gram Naive Bayes. 짧은 후속 발화가 어떤 행동인지 보조 판단
문맥 라벨 분류기	strict/soft/OR/교체/제외/가족/이동/시설 근거 라벨을 보조 판단
RAG/Chroma 검색	저장된 관광 카드와 문서에서 후보를 찾고 추천 근거 확보
TourAPI/로컬 카드	휠체어, 주차, 화장실, 수유실, 점자블록 등 접근성 근거 확인
LLM	기본 OFF. 커도 후보 생성이 아니라 재랭킹, 설명, 검수 보조로 제한

실제 처리 흐름은 다음과 같다.

1. 규칙 파서가 지역과 명시 조건을 먼저 잡는다.
 2. 의도 분류기가 더 보기, 조건 교체, 조건 제외, 지역 변경 같은 후속 의도를 보조한다.
 3. 문맥 라벨 분류기가 둘 다 필요, 가능하면, 수어 또는 자막, 시장 제외 같은 조건 해석을 보조한다.
 4. RAG와 TourAPI/로컬 카드에서 근거 있는 후보만 가져온다.
 5. 카드 근거와 실제 chat 평가로 결과가 맞는지 확인한다.
- 따라서 현재 구조는 룰셋 단독이 아니라, 규칙 기반 제어 + ML 보조 신호 + RAG/구조화 데이터 근거 확인 조합이다. 다만 한국어의 우회 표현과 생략을 더 잘 다루려면 실제 사용자 발화와 LLM 생성 발화를 이용해 라벨을 확장하고, 이후 룰셋 함수 또는 Transformer 계열 분류기로 고정하는 방향이 필요하다.

8. 시연에서 강조할 차별점

1. 근거 기반 카드 추천
 - 장소명만 추천하지 않고, 휠체어·주차·화장실·수유실·점자블록 등 확인된 근거를 카드에 붙인다.
2. 지역 오인 방지
 - 중구처럼 여러 지역에 있는 이름은 바로 추천하지 않고 선택 질문을 한다.
3. 좁은 지역 자동 확장 금지
 - 사용자가 시군구를 명시하면 다른 지역을 임의로 섞지 않는다.
 - 부족하면 부족 안내와 근처/주변 확장 제안을 한다.
4. 후속 질문 처리
 - 더 보기, 그중 시장 말고, 유모차 말고 휠체어, 서울 중구 말고 부산 중구 같은 흐름을 유지한다.
5. 환각 억제
 - 근거가 없으면 카드를 억지로 만들지 않고, 조건 완하나 지역 확장을 제안한다.
6. ML/NLP 기반 개선 과정
 - 의도 분류, 문맥 라벨, 새 평가셋, 실제 chat 평가를 분리해 단순 프롬프트 수정이 아니라 반복 가능한 검증 흐름을 만들었다.
7. 시연 안정성
 - live API가 불안해도 fallback/RAG로 기본 시연이 가능하다.

9. 명시할 한계

한계	현재 대응
접근성 정보는 현장 보장이 아님	“방문 전 공식 안내나 전화 확인” 문구 유지
일부 지역은 공식 무장에 상세가 적음	계룡시처럼 확인된 후보만 제공하고 근처 확장 제안
데이터 신선도	live 조회와 향후 주기적 갱신 배치로 보완
ML 일반화	새 평가셋과 실제 chat 평가를 분리해 과장 방지
정식 운영 준비	배포, 모니터링, 관리자 도구, 사람 검수는 후속

10. 교수님께 확인받고 싶은 질문

이 검토 자료에서는 관광 추천 챗봇을 구성하는 데이터 검색, 자연어 처리, ML 및 Transformer 계열 실험, 실제 chat 평가의 연결 방식이 타당한지 확인받고자 한다.

현재 구조는 다음 흐름이다.

- 후보 확보: TourAPI와 RAG/fallback으로 근거 있는 관광 카드를 찾는다.
- 문맥 해석: 규칙 기반 처리와 ML 보조 분류기로 의도와 조건을 해석한다.
- 모델 비교: Naive Bayes, LinearSVC, LogisticRegression, Transformer를 비교해 런타임 채택 여부를 판단한다.
- 품질 확인: 같은 평가셋을 보고 보강한 결과와, 처음 보는 새 문장·실제 chat 응답 평가를 분리해 확인한다.

이 흐름을 기준으로 아래 내용을 확인받고 싶다.

1. RAG, TourAPI, fallback을 함께 쓰는 구조가 관광 추천 챗봇의 근거성과 안정성을 높이는 방향으로 타당한가?
2. 의도 분류와 문맥 해석을 LLM 프롬프트에만 맡기지 않고 별도 규칙/ML 단계로 분리한 판단이 적절한가?
3. 규칙 기반 처리를 중심에 두고 ML 분류기를 보조 신호로 쓰는 현재 구조가 실무적으로 설득력 있는가?
4. 규칙 기반 기준선은 무장에 관광 시연 범위에서 지역·접근성 조건·제외·교체 표현을 직접 정의한 결과다. 새 문장 평가에서는 rule-only micro-F1 0.9091, hybrid LinearSVC 0.9012, hybrid LogisticRegression 0.8968이었고, Transformer도 locked test 단독 micro-F1 0.8594로 기존 구조를 넘지 못했다. 다만 한국어는 우회 표현과 생략이 많아 규칙만으로는 편협해질 수 있다. 이 결과를 “현재 범위에서는 규칙 중심 유지, 장기적으로는 발화 수집과 라벨 확장 필요”로 해석하는 것이 타당한가?
5. 오류를 발견한 평가셋에서 다시 점수가 오른 결과는 회귀 점검으로 보고, 처음 보는 새 문장과 실제 챗봇 응답 카드로 별도 확인했다. 이런 평가 방식이 특정 단어와 규칙에만 맞춰지는 문제를 줄이는데 충분한가, 아니면 실제 사용자 발화 수집을 더 우선해야 하는가?
6. LLM을 후보 생성 엔진이 아니라 재랭킹, 설명, 검수 보조로 제한한 방향이 RAG 챗봇 구조에 맞는가?
7. 앞으로 보강한다면 데이터 품질 검수, 문맥 평가셋 확장, 모델 고도화, 운영 로그 분석 중 무엇을 우선해야 하는가?